

ZAAWANSOWANA ANALIZA I PREDYKCJA ROTACJI PRACOWNIKÓW

Raport Wynikowy i Rekomendacje Strategiczne (People Analytics)

Typ dokumentu: Raport Analityczno-Biznesowy (Wdrożenie Systemu Klasyfikacji AI)

Zbiór danych: IBM HR Analytics Employee Attrition & Performance

Status hipotezy:

POTWIERDZONA (SKUTECZNOŚĆ: 97.00%)

Data opracowania: 12 czerwca 2026 r.

Wymóg formalny: Pełne omówienie wyników z wyłączeniem bloków kodu technicznego

Zastosowany model: Zoptymalizowany Klasyfikator Zespołowy XGBoost

CZĘŚĆ ANALITYCZNA

1. Wybór i uzasadnienie zestawu danych

Współczesne zarządzanie kapitałem ludzkim w organizacjach coraz silniej opiera się na podejściu opartym na faktach (*Data-Driven HR*). Jednym z najbardziej kosztownych i krytycznych wyzwań stojących przed działami personalnymi jest zjawisko niepożądanego rotacji pracowników (*Employee Attrition*). Generuje ono wysokie koszty bezpośrednie, związane z procesami rekrutacji i wdrażania nowo zatrudnionych osób, jak również koszty pośrednie, przejawiające się w utracie wiedzy eksperckiej, destabilizacji pracy zespołów oraz czasowym spadku produktywności operacyjnej.

Prezentowany raport opiera się na referencyjnym, przekrojowym zbiorze danych **IBM HR Analytics Employee Attrition & Performance**. Zbiór ten obejmuje pełne profile 3000 pracowników opisane za pomocą 35 zróżnicowanych cech diagnostycznych. Dane te charakteryzują się wysoką unikalnością, ponieważ łączą cechy demograficzne pracowników (wiek, płeć, stan cywilny) z czynnikami psychospołecznymi (satisfakcja ze środowiska pracy, poziom zaangażowania, satisfakcja z wykonywanych zadań), strukturą finansowo-ekonomiczną (miesięczne wynagrodzenie, poziom stanowiska, posiadane opcje na akcje) oraz historią kariery wewnątrz organizacji (łączny staż, lata spędzone w firmie, czas od ostatniego awansu czy staż pod okiem obecnego menedżera).

Głównym zadaniem postawionym przed algorytmami Sztucznej Inteligencji (AI) jest realizacja procesu **uczenia nadzorowanego** nakierowanego na klasyfikację binarną. Model ma za zadanie zidentyfikować ukryte, nieliniowe wzorce zachowań i powiązań między cechami, aby trafnie przewidzieć wartość zmiennej docelowej (*Attrition*), wskazującej, czy dany pracownik odejdzie z organizacji. Co kluczowe dla celów biznesowych, wdrożona analityka pozwala na wyznaczenie globalnej ważności cech (*Feature Importance*), co transformuje model matematyczny z czarnej skrzynki w transparentne narzędzie optymalizacji polityki retencyjnej firmy.

2. Analiza eksploracyjna zbioru danych (EDA)

Ewaluacja struktury technicznej, kompletności, rozkładów oraz współliniowości cech w zbiorze danych.

2.1 Struktura danych oraz audyt kompletności

Wstępna analiza struktury bazy danych wykazała, że zbiór składa się z 3000 rekordów. Cechy opisujące pracowników są reprezentowane przez 26 kolumn numerycznych (typu całkowitoliczbowego) oraz 9 kolumn kategorycznych przechowujących wartości tekstowe.

Przeprowadzony szczegółowy audyt brakujących danych wykazał **stuprocentową kompletność zbioru** – w żadnej z kolumn nie odnotowano wartości pustych (Null / NaN). Oznacza to brak konieczności stosowania statystycznych metod imputacji (uzupełniania danych medianą lub algorytmami najbliższych sąsiadów), co gwarantuje pełną autentyczność sygnałów wejściowych branych pod uwagę podczas modelowania.

2.2 Opis statystyczny rozkładów

W celu zrozumienia skali i rozpiętości cech ilościowych, wyznaczono podstawowe miary tendencji centralnej oraz dyspersji. Analiza rozkładów ujawnia szerokie zróżnicowanie populacji badanych pracowników. Przykładowo, wiek pracowników waha się w granicach od 18 do 60 lat (średnia wieku wynosi około 37 lat). Szczególnie silną dyspersją charakteryzuje się zmienna dochodu miesięcznego (*MonthlyIncome*) – minimalne zarobki wynoszą 1009 USD, natomiast maksymalne sięgają aż 19999 USD miesięcznie, co bezpośrednio odzwierciedla zróżnicowaną strukturę hierarchiczną (poziomy stanowisk od 1 do 5).

	count	mean	std	min	25%	50%	75%	max
Age	3000.0	36.884667	9.310080	18.0	30.00	35.0	43.00	60.0
DailyRate	3000.0	794.002000	406.103612	102.0	448.00	792.5	1150.25	1499.0
DistanceFromHome	3000.0	9.300333	8.158165	1.0	2.00	7.0	14.00	29.0
Education	3000.0	2.932667	1.051587	1.0	2.00	3.0	4.00	5.0
EmployeeCount	3000.0	1.000000	0.000000	1.0	1.00	1.0	1.00	1.0
EmployeeNumber	3000.0	1500.500000	866.169729	1.0	750.75	1500.5	2250.25	3000.0
EnvironmentSatisfaction	3000.0	2.714333	1.099605	1.0	2.00	3.0	4.00	4.0
HourlyRate	3000.0	66.660333	20.425557	30.0	49.00	67.0	84.25	100.0
JobInvolvement	3000.0	2.735000	0.715737	1.0	2.00	3.0	3.00	4.0
JobLevel	3000.0	2.069000	1.131665	1.0	1.00	2.0	3.00	5.0
JobSatisfaction	3000.0	2.734667	1.100607	1.0	2.00	3.0	4.00	4.0
MonthlyIncome	3000.0	6523.585333	4848.078118	1009.0	2835.75	4741.0	8620.00	19999.0
MonthlyRate	3000.0	14432.892333	7142.085503	2094.0	8043.75	14399.0	20652.00	26999.0
NumCompaniesWorked	3000.0	2.674667	2.512289	0.0	1.00	2.0	4.00	9.0
PercentSalaryHike	3000.0	15.255667	3.630523	11.0	12.00	14.0	18.00	25.0
PerformanceRating	3000.0	3.156667	0.363547	3.0	3.00	3.0	3.00	4.0
RelationshipSatisfaction	3000.0	2.682667	1.078743	1.0	2.00	3.0	4.00	4.0
StandardHours	3000.0	80.000000	0.000000	80.0	80.00	80.0	80.00	80.0
StockOptionLevel	3000.0	0.785000	0.842424	0.0	0.00	1.0	1.00	3.0
TotalWorkingYears	3000.0	11.153000	7.992260	0.0	6.00	9.0	15.00	40.0
TrainingTimesLastYear	3000.0	2.785000	1.263846	0.0	2.00	3.0	3.00	6.0
WorkLifeBalance	3000.0	2.768333	0.715659	1.0	2.00	3.0	3.00	4.0
YearsAtCompany	3000.0	6.849667	6.034612	0.0	3.00	5.0	9.00	40.0
YearsInCurrentRole	3000.0	4.089333	3.585476	0.0	2.00	3.0	7.00	18.0
YearsSinceLastPromotion	3000.0	2.109333	3.067222	0.0	0.00	1.0	2.25	15.0
YearsWithCurrManager	3000.0	4.000333	3.575182	0.0	2.00	3.0	7.00	17.0

2.3 Eliminacja cech stałych (Zero-Variance)

W toku analizy zidentyfikowano trzy zmienne, które charakteryzują się zerową wariancją – przyjmują dokładnie jedną, identyczną wartość dla każdego rekordu w bazie danych. Są to cechy: EmployeeCount, Over18 oraz StandardHours. Z punktu widzenia matematycznego i teorii informacji, zmienne o zerowej

wariancji nie wnoszą żadnej siły predykcyjnej (nie różnicują próbek), a sztucznie zwiększają wymiarowość problemu. Zostały one zakwalifikowane do bezwzględnego usunięcia przed etapem modelowania. Dodatkowo, cecha `EmployeeNumber`, stanowiąca losowy identyfikator pracownika, również została usunięta jako szum informacyjny.


2.4 Analiza korelacji liniowej ze zmienną docelową

Aby ocenić siłę i kierunek bezpośrednich zależności liniowych, przekształcono zmienną docelową oraz kluczową cechę kategoriową (praca w godzinach nadliczbowych) na format binarny (0/1). Wyznaczone współczynniki korelacji liniowej Pearsona pozwoliły wyłonić najsilniejsze, bezpośrednie stymulatory i inhibitory rotacji.

Nazwa zmiennej diagnostycznej	Współczynnik korelacji z odejściem (Attrition)	Charakterystyka wpływu
OverTime (Godziny nadliczbowe)	+0.239	Główny bezpośredni stymulator rotacji
DistanceFromHome (Dystans do pracy)	+0.076	Słaby stymulator rotacji
NumCompaniesWorked (Liczba byłych firm)	+0.069	Niski wzrost skłonności do zmiany pracy
JobSatisfaction (Satysfakcja z pracy)	-0.111	Wzrost satysfakcji ogranicza odejścia
StockOptionLevel (Opcje na akcje)	-0.148	Silny czynnik retencyjny/lojalnościowy
Age (Wiek pracownika)	-0.173	Młodszy pracownicy odchodzą statystycznie częściej
JobLevel (Poziom stanowiska)	-0.186	Wysokie stanowisko silnie stabilizuje zatrudnienie
MonthlyIncome (Miesięczny dochód)	-0.186	Kluczowy ekonomiczny inhibitor odejść
TotalWorkingYears (Łączny staż pracy)	-0.192	Najsilniejszy liniowy czynnik stabilizujący

2.5 Graficzna interpretacja dystrybucji danych

Wizualizacja struktury danych ujawnia dwa fundamentalne wyzwania modelowe. Po pierwsze, rozkład zmiennej docelowej jest wysoce niebalansowany (stosunek osób pozostających do odchodzących wynosi w przybliżeniu 5:1). Wymaga to rygorystycznego stosowania stratyfikacji przy podziale danych na zbiory treningowe/testowe oraz wyklucza stosowanie ogólnej dokładności (Accuracy) jako jedynej metryki sukcesu algorytmu. Po drugie, zaobserwowano silną współliniowość (*Multicollinearity*) między cechami strukturalnymi, np. między `JobLevel` a `MonthlyIncome` współczynnik korelacji wynosi aż **0.95**, co utrudnia tradycyjne modelowanie liniowe i faworyzuje nieliniowe modele drzewiaste.



3. Sformułowanie hipotezy badawczej

W oparciu o wnioski płynące z analizy rozkładów i macierzy korelacji sformułowano następujące założenie badawcze:

Treść hipotezy badawczej:

Zastosowanie zaawansowanych, nieliniowych algorytmów uczenia maszynowego (opartych na zespołach drzew decyzyjnych) w połączeniu z automatycznym, matematycznym równoważeniem wag klas oraz procedurą wielokryterialnej optymalizacji progu prawdopodobieństwa decyzyjnego, pozwoli na zbudowanie modelu predykcyjnego, który osiągnie na zbiorze testowym ogólną dokładność (**Accuracy**) na poziomie minimum **85%** oraz czułość (**Recall**) dla klasy pozytywnej (osoby odchodzące) wynoszącą co najmniej **70%**.

Uzasadnienie biznesowe: Koszt pominięcia pracownika planującego odejście (błąd typu *False Negative*) przewyższa wielokrotnie koszt fałszywego zidentyfikowania pracownika jako stabilnego (błąd typu *False Positive*). Wysoka czułość (Recall) jest kluczowym wskaźnikiem operacyjnym, który pozwala działom HR na podjęcie natychmiastowych działań zapobiegawczych wobec osób realnie zagrożonych rotacją, zanim formalnie złożą wypowiedzenie.

4. Badanie aktualnego stanu wiedzy (State-of-the-Art)

W tradycyjnych systemach kadrowych (HRMS) dominowało stosowanie klasycznych modeli statystycznych – głównie regresji logistycznej oraz analizy przeżycia (model hazardów Coxa). Modele te, choć w pełni przezroczyste matematycznie, zakładają sztywne, liniowe granice decyzyjne i wykazują rażącą bezradność w obliczu złożonych interakcji czynników psychospołecznych z materialnymi (np. sytuacja, w której niski dochód jest rekompensowany przez wybitne Work-Life Balance).

Współczesna literatura naukowa z zakresu *Data Science* jednoznacznie wskazuje na wyższą efektywność metod nieparametrycznych, takich jak Lasy Losowe (Random Forest) oraz algorytmy z rodziny boostingu

gradientowego (XGBoost, LightGBM). Aby wyeliminować problem natury "czarnej skrzynki" (*Black Box*), nowoczesne wdrożenia biznesowe bezwzględnie integruje się z metodami wyjaśnialnej sztucznej inteligencji (**XAI**), takimi jak wartości **SHAP** lub globalne profile istotności cech. Pozwala to na pełną personalizację analizy ryzyka dla każdego pracownika osobno.

5. Teoretyczna analiza porównawcza kandydatów na model

Przed przystąpieniem do implementacji systemowej dokonano szczegółowej analizy czterech zróżnicowanych klasyfikatorów matematycznych:

- **Regresja Logistyczna:** Model liniowy, szybki obliczeniowo i łatwy w interpretacji. Wykazuje jednak drastyczną wrażliwość na współliniowość cech (sprzężenie dochodu z poziomem stanowiska) i zakłada uproszczoną granicę podziału przestrzeni, przez co służy w projekcie wyłącznie jako punkt odniesienia (*Baseline*).
- **Drzewa Decyzyjne:** Model intuicyjny, automatycznie modelujący interakcje zmiennych kategoriycznych i ciągłych bez wymogu skalowania. Cechuje się jednak ekstremalną podatnością na przeuczenie (*overfitting*) i wysoką wariancją struktury przy najmniejszych fluktuacjach danych.
- **Las Losowy (Random Forest):** Zaawansowany model zespołowy oparty na koncepcji *Baggingu*. Buduje populację niezależnych drzew na losowych podpróbkach danych i cech, agregując ich oceny poprzez głosowanie większościowe. Cechuje się wybitną stabilnością, jest niewrażliwy na skorelowane predyktory i doskonale współgra z charakterystyką danych tabelarycznych IBM HR.
- **Maszyna Wektorów Nośnych (SVM):** Poszukuje hiperpłaszczyzny rozdzielającej klasy z maksymalnym marginesem w przestrzeniach nieliniowych (za pomocą jądra RBF). Wymaga jednak rygorystycznego skalowania danych i jest trudna w bezpośredniej interpretacji menedżerskiej.

CZĘŚĆ IMPLEMENTACYJNA

6. Przygotowanie danych i inżynieria cech

Konstrukcja potoków przetwarzania, kodowanie i optymalny podział danych.

W celu zachowania pełnego rygoru metodologicznego oraz całkowitego wykluczenia zjawiska wycieku informacji ze zbioru testowego do treningowego (*Data Leakage*), inżynieria cech została zaimplementowana wewnątrz scentralizowanych potoków przetwarzania.

Zbiór danych został oczyszczony z pięciu cech nieprzydatnych (stałych lub indeksowych). Następnie zmienne wejściowe podzielono na dwa strumienie: cechy kategoryczne poddano kodowaniu metodą *One-Hot Encoding* z usuwaniem pierwszej kolumny (w celu unikania pułapki współliniowości), a cechy numeryczne poddano standaryzacji (transformacja Z-score sprowadzająca średnią do 0 i wariancję do 1). Cały zbiór został podzielony na część treningową (80% - 2400 rekordów) oraz testową (20% - 600 rekordów) przy zastosowaniu ****stratyfikacji**** względem zmiennej docelowej, co zagwarantowało identyczne proporcje klas (1:5) w obu podzbiorach.

7. Szkolenie, walidacja krzyżowa oraz optymalizacja progu decyzyjnego

Proces treningu i dostrajania hiperparametrów modeli przeprowadzono przy użyciu strategii 5-krotnej króś-walidacji stratyfikowanej (*Stratified 5-Fold Cross-Validation*) połączonej z przeszukiwaniem siatki (*GridSearchCV*). Zgodnie z pierwszym warunkiem postawionej hipotezy, głównym kryterium optymalizacji siatki była metryka ogólnej dokładności (`scoring='accuracy'`).

W celu zwalczania problemu asymetrii klas zrezygnowano ze stosowania metod syntetycznych (typu SMOTE), które generują sztuczne próbki i mogą zniekształcać nieliniowe granice decyzyjne. Zamiast tego zaimplementowano wewnętrzne, wagowe równoważenie kosztu błędu klasy mniejszościowej (parametr `class_weight='balanced'` dla Lasu Losowego oraz proporcja `scale_pos_weight` dla XGBoost).


Po zakończeniu walidacji algorytm **XGBoost** osiągnął najwyższą stabilność z wynikiem CV Accuracy na poziomie **97.12%** (wobec 97.00% dla Lasu Losowego) i został wybrany jako model docelowy. Następnie na danych treningowych przeprowadzono precyzyjne przeszukiwanie przestrzeni progów prawdopodobieństwa. Tradycyjny próg decyzyjny (0.50) został obniżony do poziomu **0.260**. Taka korekta matematyczna pozwoliła drastycznie podnieść czułość modelu (zdolność wykrywania odejść) przy minimalnym koszcie wzrostu błędów typu False Positive, gwarantując pełną realizację obu kryteriów sformułowanej hipotezy.

Nazwa algorytmu (Wersja bazowa)	Accuracy (Zbiór testowy)	F1-Score dla klasy 'Tak'	Metryka ROC-AUC
Regresja Logistyczna (Baseline)	0.768	0.502	0.846
Las Losowy (Random Forest)	0.963	0.874	0.985
XGBoost Classifier	0.968	0.899	0.990

8. Kompleksowa analiza wyników i weryfikacja hipotezy badawczej

Ostateczny test zoptymalizowanego modelu **XGBoost** (z progiem decyzyjnym ustawionym na poziomie **0.260**) przeprowadzono na odseparowanej próbce testowej 600 pracowników. Zdolność separacyjna modelu okazała się wybitna – obszar pod krzywą ROC (metryka **ROC-AUC**) osiągnął stabilną wartość **0.9911**.

Model wykazał się rewelacyjną skutecznością operacyjną, poprawnie klasyfikując 89 spośród 99 rzeczywistych przypadków odejść pracowników, co przełożyło się na czułość (**Recall**) na poziomie **89.90%**. Jednocześnie model utrzymał bardzo wysoką precyzję (Precision = 92%), popełniając jedynie 8 błędów typu fałszywy alarm (False Positive) na grupie 501 pracowników stabilnych. Ogólna dokładność klasyfikacji (**Accuracy**) wyniosła **97.00%**.



Wygenerowany profil istotności cech dostarcza kluczowych wniosków zarządczych. Najsilniejszym nieliniowym predyktorem stymulującym rotację okazało się specyficzne zajmowanie stanowiska dyrektora ds. badań (JobRole_Research Director), co sygnalizuje konieczność audytu warunków pracy w tym pionie. Drugim najważniejszym stymulatorem jest praca w godzinach nadliczbowych (OverTime_Yes), co potwierdza destrukcyjny wpływ przeciążenia zadaniami na lojalność kadr. Z kolei najważniejszymi czynnikami stabilizującymi (inhibitorami rotacji) okazały się wysoki poziom stanowiska (JobLevel) oraz wysoki poziom wynagrodzenia zasadniczego (MonthlyIncome). Znamienny jest również istotny wpływ stanu cywilnego – status singla (MaritalStatus_Single) znacząco zwiększa statystyczną podatność na zmianę pracodawcy.

WERYFIKACJA FORMALNA KRYTERIÓW HIPOTEZY BADAWCZEJ

Metryka Ewaluacji	Uzyskany Wynik	Próg Wymagany	Status Walidacji
Ogólna Dokładność (Accuracy)	97.00%	$\geq 85.00\%$	✓ SPEŁNIONY
Czułość Modelu (Recall dla klasy 'Tak')	89.90%	$\geq 70.00\%$	✓ SPEŁNIONY

[DECYZJA]: Sformułowana hipoteza badawcza została w pełni **POTWIERDZONA**. Opracowany system klasyfikacyjny bazujący na algorytmie XGBoost spełnia z nawiązką wszystkie rygory matematyczne oraz kryteria biznesowe i kwalifikuje się do wdrożenia produkcyjnego jako System Wczesnego Ostrzegania (EWS) w strukturach HR.

9. Zbiorcze podsumowanie porównawcze modeli

W celu przedstawienia pełnego obrazu prac zrealizowanych w ramach potoku uczenia maszynowego, w tabeli poniżej zestawiono końcowe, zwalidowane wyniki wszystkich trzech struktur modelowych testowanych na identycznej, odseparowanej próbie testowej. Podsumowanie to jednoznacznie uzasadnia wybór zoptymalizowanego algorytmu XGBoost jako lidera predykcji.

Model Klasyfikacyjny	Dokładność (Accuracy)	Czułość (Recall Yes)	F1-Score (Klasa Yes)	Obszar pod krzywą (ROC-AUC)
Regresja Logistyczna (Model Bazowy - Baseline)	76.8%	70.7%	50.2%	0.846
Las Losowy (Random Forest - Zoptymalizowany)	97.0%	82.8%	90.1%	0.990
XGBoost Classifier (Zoptymalizowany próg decyzyjny 0.260)	97.0%	89.9%	90.8%	0.991